

PROGRAMA DE PÓS-GRADUAÇÃO EM INFORMÁTICA

Nome: Frederico Guth

CPF: 273.723.818-86

Proposta de Projeto de Pesquisa

Título: Transferência de Aprendizado em Visão Computacional

Linha de Pesquisa: Sistemas de Computação

Área de Pesquisa: Visão Computacional

1 Introdução

Recentes avanços na área de Visão Computacional tornam possíveis aplicações que são capazes de reconhecer pessoas, lugares e objetos com acurácia super-humana [1], diagnosticar câncer de pele tão bem quanto dermatologistas [2], ver através de paredes usando sinais de rádio [3], entre tantas outras.

Neste contexto, é compreensível se iludir com o sensacionalismo e até pensar que Aprendizado Profundo (DL¹) seja uma área "resolvida"—longe disso. Os melhores casos de sucesso foram desenvolvidos exclusivamente para uma tarefa, em um único domínio; sobre a premissa básica que os dados com os quais o modelo será testado são do mesmo espaço de características e possuem a mesma distribuição que os dados de treinamento [4]. Em outras palavras, temos algoritmos cada vez melhores em encontrar padrões em uma grande quantidade de dados rotulados, mas ainda deficientes na capacidade de generalizar para condições diferentes daquelas encontradas no treinamento.

Transferência de Aprendizado (TL²) é a área que pesquisa como armazenar conhecimento adquirido em um domínio ou tarefa e aplicá-lo a um novo problema. Essa capacidade permite lidar com a insuficiência de dados rotulados e é absolutamente necessária para o uso de inteligência artificial em larga escala que vai além das tarefas e domínios para os quais a disponibilidade de dados rotulados é abundante. Em outras palavras, apesar de todo o sucesso, os modelos atuais atacam apenas os casos fáceis em termos de disponibilidade de dados. Para lidar com a variabilidade cauda longa do mundo, precisamos aprender a transferir aprendizado.

2 Justificativa

Humanos e animais conseguem aprender com poucas amostras [5] e apresentam extraordinária capacidade de generalização que os algoritmos de DL ainda estão longe de alcançar. Tal fato é prova que há grande potencial ainda inalcançado na área de TL. Na prática, TL ainda é tratada de uma forma *ad hoc*, sendo os métodos de transferências meras extensões dos algoritmos de aprendizado utilizados [6].

Essa dicotomia entre a importância do problema e a inexistência de práticas e teorias consolidadas, tornam TL um campo promissor e interessante para pesquisa. Opinião essa compartilhada por especialistas renomados:

"Transferência de Aprendizado será o próximo motor do sucesso comercial com
Aprendizado de Máquinas." —Andrew Ng, Tutorial NIPS 2016 [7]

¹ Deep Learning

² Transfer Learning

3 Objetivos

O objetivo geral do presente projeto é desenvolver e investigar métodos de transferência de aprendizado para problemas de visão computacional. Espera-se criar métodos mais versáteis e eficientes, requerendo menos dados para serem treinados.

3.1 Objetivos específicos

Como objetivos específicos, pretende-se:

- Investigar e reproduzir pesquisas recentes em: (a) *self-supervised learning*; (b) *domain-adaptation*, com interesse especial em adaptação de dados sintéticos; (c) *zero-shot, one-shot* e *few-shots learning*; (d) *Adversarial Transfer Learning*;
- Propor novos métodos de transferência de aprendizado;
- Publicar papers em revistas e conferências.

4 Revisão da Literatura

Apesar de Transferência de Aprendizado ser uma técnica bastante utilizada em diversos artigos importantes, a literatura específica é desatualizada e inconsistente.

O livro *Learning to Learn* [8], um compêndio por Thrun e Pratt de diversos trabalhos do workshop NeurIPS de 1995, atualizado em 1998, apresenta o campo e, de certa forma, formaliza o início do estudo da área. Ainda hoje é um dos raros livros que se propõem a discutir especificamente Transferência de Aprendizado no contexto de Aprendizado de Máquinas.

O excelente artigo *A Survey on Transfer Learning* [4] de Pan e Young, é a principal referência há quase 10 anos, sendo utilizado como base em outros trabalhos [9, 5, 10]. Apesar de mostrar um panorama amplo, já mostra alguns sinais de desatualização devido a velocidade do progresso da área. Iniciativas recentes como [10] buscam atualizar o trabalho de [4] tratando de desenvolvimentos recentes como *adversarial based transfer learning*, mas se focam nos métodos de transferência para aprendizado profundo supervisionado.

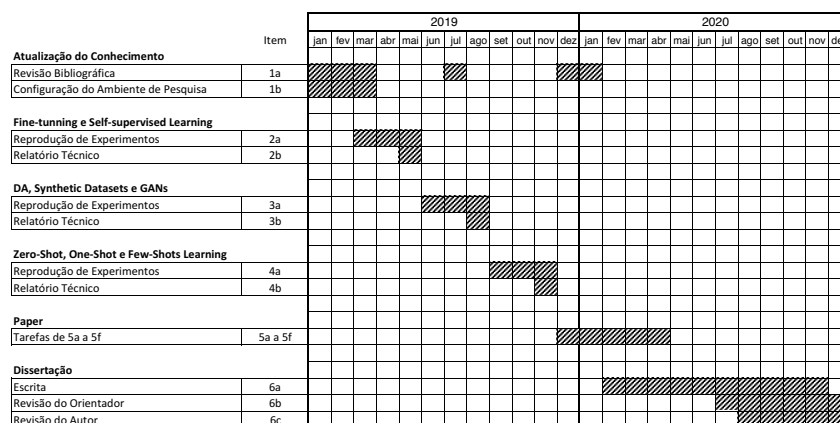
5 Metodologia

A metodologia do projeto se baseia na leitura sistemática de artigos e livros sobre o assunto e reprodução experimental de resultados obtidos em trabalhos selecionados de Transferência de Aprendizado nas melhores conferências de Visão Computacional.

Adicionalmente, espera-se que o proponente participe de congressos de seminários, sempre que possível, apresentando resultados obtidos.

As seguintes tarefas serão executadas no desenvolvimento deste projeto:

- ## 7 Cronograma



Bibliografia

- [1] J. Deng L. Fei-Fei. Where have we been? where are we going?, 2017. [Online; acessada 28 de Junho de 2018].
- [2] H A Haenssle, C Fink, R Schneiderbauer, F Toberer, T Buhl, A Blum, A Kalloo, A Ben Hadj Hassen, L Thomas, A Enk, L Uhlmann, Reader study level I, and level II Groups. Man against machine: diagnostic performance of a deep learning convolutional neural network for dermoscopic melanoma recognition in comparison to 58 dermatologists. *Annals of Oncology*, 29(8):1836–1842, 2018.
- [3] Mingmin Zhao, Tianhong Li, Mohammad Abu Alsheikh, Yonglong Tian, Hang Zhao, Antonio Torralba, and Dina Katabi. Through-wall human pose estimation using radio signals. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 7356–7365, 2018.
- [4] Sinno Jialin Pan and Qiang Yang. A survey on transfer learning. *IEEE Trans. on Knowl. and Data Eng.*, 22(10):1345–1359, October 2010.
- [5] Ian J. Goodfellow, Yoshua Bengio, and Aaron C. Courville. *Deep Learning*. Adaptive computation and machine learning. MIT Press, 2016.
- [6] Lisa Torrey and Jude Shavlik. Transfer learning. In *Handbook of Research on Machine Learning Applications and Trends: Algorithms, Methods, and Techniques*, pages 242–264. IGI Global, 2010.
- [7] Andrew Ng. Nuts and bolts of applying deep learning, 2016. [Online; acessado 20 de novembro de 2018.].
- [8] Sebastian Thrun and Lorien Pratt, editors. *Learning to Learn*. Kluwer Academic Publishers, Norwell, MA, USA, 1998.
- [9] Gabriela Csurka. *Domain adaptation in computer vision applications*. Springer, 2017.
- [10] Chuanqi Tan, Fuchun Sun, Tao Kong, Wenchang Zhang, Chao Yang, and Chunfang Liu. A survey on deep transfer learning. In *International Conference on Artificial Neural Networks*, pages 270–279. Springer, 2018.